

Memoria Persistente y Resumen Automático del Agente

Capa de persistencia de largo plazo por `Session_ID` sobre la arquitectura del M2 — lectura de contexto, inyección semántica y summarization automática. · Lleyton Murphy

Chat Trigger

Data Table (memoria)

IF nuevo/recurrente


Inyección de contexto

Tools Agent

Summarization >5 msgs

JSON estructurado

Página 1 · Arquitectura completa del lienzo (n8n)



Circuito híbrido de persistencia (Lectura → Filtro → Escritura), aislado por `Session_ID`: se lee la memoria por ID; un IF separa usuarios nuevos (crea registro limpio, sin variables vacías) de recurrentes (inyecta el contexto en el System Prompt). Al superar 5 mensajes, un LLM económico consolida la charla en un JSON limpio que sobrescribe el registro de forma idempotente. Nunca se vuelcan HTML, logs ni transcripciones completas a la base.

Implementación real y probada. Flujo construido y ejecutado en n8n Cloud (workflow ID P2rHab3kLg3Sm1bI). Los diagramas son fieles al lienzo real y los datos de las páginas 2–3 provienen de ejecuciones reales. La base de memoria se implementó con la **Data Table nativa de n8n** (persistencia sin credenciales), equivalente 1:1 a Airtable en columnas y tipos.

Página 2 · Prompt de summarization (salida JSON forzada)

Nodo **Summarization (Resumen JSON)** — Basic LLM Chain con modelo económico **GPT-4o-mini** (temperatura 0) y un **Structured Output Parser** que obliga el esquema. Se activa solo cuando `message_count > 5`.

System Message (prompt exacto usado en el modelo mini)

```
Sos un modulo de summarization de contexto. Recibis el resumen previo de una
sesion y el ultimo intercambio (usuario + asistente). Tu UNICA tarea es devolver
un objeto JSON valido, sin texto adicional, sin markdown y sin comillas de codigo,
con EXACTAMENTE esta forma:
{ "asunto_principal": string, "puntos_clave": array de strings, "accion_requerida": string }
REGLAS Estrictas:
- "asunto_principal": una frase que consolide el estado actual del caso del usuario.
- "puntos_clave": entre 2 y 5 hechos duros, accionables y no redundantes.
- "accion_requerida": el proximo paso concreto a realizar.
- PROHIBIDO incluir HTML, logs tecnicos, payloads o transcripciones completas.
- Se breve, factual y en espanol neutro.
```

User Message (historial que se envía, con expresiones nativas de n8n)

```
Resumen previo de la sesion:
{{ $('Contexto listo').item.json.last_summary }}

Nuevo intercambio a integrar:
Usuario: {{ $('Contexto listo').item.json.chatInput }}
Asistente: {{ $json.output }}
```

Esquema de salida forzado (Structured Output Parser)

```
{
  "asunto_principal": "string",
  "puntos_clave": [ "string", "... " ],
  "accion_requerida": "string"
}
```

Salida real generada en una ejecución (guardada en la columna `resumen_consolidado`, sobrescribiendo el registro de forma idempotente):

```
{
  "asunto_principal": "Lleyton busca roles de Data Analyst remoto en LATAM con salario publicado.",
  "puntos_clave": [
    "Interés en roles de Data Analyst remoto",
    "Preferencia por zona horaria LATAM",
    "Salario publicado es un requisito"
  ],
  "accion_requerida": "Revisar las vacantes proporcionadas y seleccionar las de interés."
}
```

Página 3 · Esquema de la base de memoria

Base relacional de memoria de largo plazo, aislada por Session_ID. Implementada como **Data Table de n8n** (portable a Airtable con idénticas columnas y tipos). Un registro por sesión; se lee al inicio y se sobrescribe al cierre.

Columnas y tipos

Columna	Tipo	Descripción / metadato
session_id	string	Identificador único de sesión. Clave de aislamiento : filtra el registro exacto y blinda contra la amnesia cruzada.
user_name	string	Nombre del usuario, recuperado e inyectado en el System Prompt.
fecha_actualizacion	string (ISO 8601)	Timestamp de la última escritura (para auditoría / orden).
resumen_consolidado	string (JSON)	Objeto {asunto_principal, puntos_clave, accion_requerida} de la summarization. Es el "last_summary" que se reinyecta.
estado_del_caso	string	Estado / próxima acción del caso (Status).
datos_clave	string (JSON)	Array de hechos duros y accionables (puntos_clave). Nunca transcripciones ni payloads pesados.
message_count	number	Contador de intercambios de la sesión. Dispara la summarization al superar 5.
id · createdAt · updatedAt	system	Metadatos automáticos de la Data Table (clave primaria y timestamps de fila).

Registro real de ejemplo (fila persistida)

```
session_id: "mcp-session-1789738870554"
user_name: "Lleyton"
fecha_actualizacion: "2026-09-18T13:41:22.035Z"
resumen_consolidado: "{\"asunto_principal\":\"Lleyton busca roles de Data Analyst remoto en LATAM...\", \"puntos_clave\":[...], \"accion_requerida\":\"...\"}"
estado_del_caso: "Revisar las vacantes proporcionadas y seleccionar las de interés."
datos_clave: "[\"Interés en Data Analyst remoto\", \"Preferencia LATAM\", \"Salario publicado\"]"
message_count: 1
```

Inyección de contexto en el System Prompt del agente

Los datos recuperados se insertan con delimitadores rígidos (protección anti prompt-injection):

```
CONFIGURACION DE IDENTIDAD Y MEMORIA DE LARGO PLAZO
[INICIO DE CONTEXTO COMPARTIDO]
Nombre del usuario: {{ $json.user_name }}
Estado del caso: {{ $json.estado }}
Resumen de la ultima charla: {{ $json.last_summary }}
[FIN DEL CONTEXTO COMPARTIDO]
... (rol, objetivo y reglas del agente) ...
```

Verificable en vivo: workflow lleytoncito.app.n8n.cloud/workflow/P2rHab3kLg3SmlbI · Data Table "Memoria Agente M3". JSON exportado: checkpoint3_memoria_lleyton_murphy.json.