

Checkpoint Módulo 8 · Supervisor QA con AI-as-a-Judge

Lleyton Murphy · Agente de Soporte e-commerce (Lleyton Tech Store) · proyecto integrador M1 → M5 → M8

n8n


Juez gpt-4o con JSON Schema

Switch de 3 rutas

Test A/B: 10 corridas

El agente de soporte de los módulos anteriores (RAG sobre el Manual de Políticas v2.1) ya no responde directo al cliente. Ahora cada respuesta pasa por un **Juez LLM** que la califica con salida JSON forzada. Un **Switch** decide si se envía, si se corrige con la crítica del Juez o si se escala a un humano. Cada veredicto queda registrado en una tabla de auditoría.

1. Arquitectura del supervisor



Nodo	Función
Recuperar contexto (Base de Conocimiento)	Lee las secciones del manual desde la Data Table <i>Base Conocimiento M8</i> (equivalente a <i>Airtable</i>) y elige las 2 más relevantes.
Agente Soporte (Arquitectura A / B)	Nodo OpenAI con el System Prompt RAG del M5 (cita la fuente y aplica la regla "No sé"). El modelo cambia según la arquitectura.
Payload JSON para el Juez	Arma el objeto {query_usuario, contexto_recuperado, respuesta_propuesta}.
Juez (AI-as-a-Judge · JSON Schema)	Nodo OpenAI gpt-4o con <i>Output Format = JSON Schema</i> : devuelve exactitud_factual, estado_veredicto, categoria_error y critica.
Procesar veredicto + costo	Valida el JSON. Si el Juez no devolviera un JSON válido, lo trata como RECHAZADO para que el Switch nunca reciba texto libre. Calcula tokens y

	costo.
Switch · Ruta según estado_veredicto	3 salidas: ACEPTAR / CORREGIR (Self-Healing) / ESCALAR (Human-in-the-loop).
Registrar veredicto (Data Table · auditoría)	Guarda cada veredicto en <i>Auditoria Juez M8</i> : repositorio externo para auditoría y fuente del dashboard.

2. Branching y umbrales

Ruta	Condición en el Switch	Acción	Límite / salida
ACEPTAR	estado_veredicto = "ACEPTADO" y exactitud_factual $\geq$ 4	Gmail envía la respuesta al cliente (salida real) y se registra el veredicto.	Fin del caso.
CORREGIR (Self-Healing)	estado_veredicto $\neq$ "RECHAZADO" y intento < 2	La crítica del Juez vuelve al agente, que reescribe la respuesta. El Juez la evalúa de nuevo.	Máximo 1 reintento. Si sigue sin aprobarse, va a ESCALAR.
ESCALAR (Human-in-the-loop)	estado_veredicto = "RECHAZADO", o salida por defecto (fallback) cuando ya no quedan reintentos	Alerta en Slack #ops-soporte con botones Aprobar / Editar y nodo Wait en modo <i>On Webhook Call</i> : la ejecución queda pausada hasta que un humano toca un botón.	Espera máx. 24 h. La decisión humana queda en la auditoría.

Por qué estos umbrales

- **Exactitud $\geq$ 4 para enviar:** 4 admite una omisión menor (por ejemplo, la cita de la sección) pero ningún dato incorrecto. Por debajo de 4 hay un error de contenido que no puede llegar al cliente.
- **Un solo reintento:** un segundo intento con la crítica corrige la mayoría de las omisiones. Más vueltas duplican el costo del Juez (el componente más caro) y alargan la respuesta sin garantía de mejora. Si falla dos veces, decide un humano.
- **RECHAZADO va directo a humano:** un dato inventado, una promesa fuera de política o un pedido de datos sensibles es un riesgo para la empresa, así que no se auto-corrige.

Qué se evitó (consigna)

Riesgo	Cómo se resolvió
Juez con respuesta en texto libre que rompe el Switch	Output Format = JSON Schema con enum en estado_veredicto, más una validación en código: si el JSON no es válido, se fuerza RECHAZADO y se escala.
Loop de auto-corrección sin límite ni salida humana	Regla intento < 2 en el Switch y fallback hacia ESCALAR (Slack + Wait).
Veredicto sin registrar	Toda corrida, por cualquier ruta, termina en <i>Registrar veredicto</i> (Data Table Auditoría Juez M8, 24 columnas).

3. Rúbrica del Juez

Prompt del Juez (System Message)

Sos el JUEZ DE CALIDAD (AI-as-a-Judge) del Agente de Soporte de Lleyton Tech Store. Recibis un objeto JSON con: query_usuario, contexto_recuperado y respuesta_propuesta. Evalua la respuesta SÓLO contra contexto_recuperado. No uses conocimiento propio.

RUBRICA exactitud_factual (entero 1-5):

- 5 = todos los datos (plazos, montos, porcentajes, condiciones) coinciden con el contexto, responde completo y cita la seccion.
- 4 = correcta y fiel al contexto, con una omision menor (por ejemplo falta la cita o un detalle secundario).
- 3 = parcialmente correcta: omite una condicion relevante o mezcla politicas distintas.
- 2 = mayormente incorrecta o incompleta, aunque no inventa datos.
- 1 = inventa datos que no estan en el contexto, contradice la politica o promete algo fuera de politica.

Caso especial: si el contexto NO contiene la respuesta y el agente responde "No sé" y ofrece derivar, es CORRECTO (5). Si en ese caso inventa una respuesta, es 1.

REGLAS DE VEREDICTO (estado_veredicto):

- ACEPTADO: exactitud_factual 4 o 5.
- CORREGIR: exactitud_factual 2 o 3 y el error se puede arreglar con tu critica.
- RECHAZADO: exactitud_factual 1, o la respuesta promete reintegros/excepciones fuera de politica, pide datos sensibles o es riesgosa para la empresa. Requiere revision humana.

categoria_error: la causa principal del problema ("ninguno" solo si la respuesta es perfecta).

critica: 1 a 3 frases concretas y accionables que digan que corregir y cual es la seccion correcta. Si es ACEPTADO con 5, escribi "Sin observaciones".

Responde ÚNICAMENTE con el JSON del esquema.

Esquema JSON forzado (Structured Outputs)

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
      "description": "Exactitud factual de la respuesta respecto del contexto (1 a 5)"
    },
    "estado_veredicto": {
      "type": "string",
      "enum": [
        "ACEPTADO",
        "CORREGIR",
        "RECHAZADO"
      ]
    },
    "categoria_error": {
      "type": "string",
      "enum": [
        "ninguno",
```

```

        "dato_inventado",
        "dato_incompleto",
        "sin_cita_de_fuente",
        "fuera_de_politica",
        "no_aplico_regla_no_se",
        "tono_o_formato"
    ]
},
"critica": {
    "type": "string",
    "description": "Critica accionable para el reintento"
}
},
"required": [
    "exactitud_factual",
    "estado_veredicto",
    "categoria_error",
    "critica"
],
"additionalProperties": false
}

```

Los dos campos que exige la consigna son `exactitud_factual` (entero 1–5) y `estado_veredicto` (ACEPTADO | CORREGIR | RECHAZADO). Se agregan `critica`, que es lo que el agente recibe en la ruta CORREGIR, y `categoria_error`, que alimenta el dashboard.

Entrada que recibe el Juez

```

{
  "query_usuario": "Puedo pagar en 12 cuotas sin interes?",
  "contexto_recuperado": "[Seccion 3.1 - Medios de pago y cuotas] Tarjeta de credito bancaria: hasta 6 cuotas sin interes ... 9 y 12 cuotas con recargo del 18% y 27% ...",
  "respuesta_propuesta": "<respuesta del agente>"
}

```

4. Experimento A/B

	Arquitectura A	Arquitectura B
Modelo del agente	gpt-4o-mini (económico)	gpt-4o (premium)
Precio por 1M tokens (entrada / salida)	USD 0,15 / 0,60	USD 2,50 / 10,00
Constante en ambas	Mismo System Prompt RAG, misma Base de Conocimiento, mismas 5 preguntas, mismo Juez (gpt-4o, temperatura 0, USD 2,50 / 10,00) y misma regla de 1 reintento.	

Hipótesis: B es más precisa en el primer intento. A, con el Self-Healing del Juez, llega a una precisión final parecida a una fracción del costo.

Métricas por corrida: exactitud del Juez (primer intento y final), ruta final, tokens reales (campo usage de la API) y costo = tokens × precio de lista (agente + Juez, incluido el reintento) y latencia.

Batería de preguntas (iguales para A y B)

#	Pregunta	Sección	Qué prueba
P1	Si me llega roto el celular, ¿me devuelven la plata?	4.2	Sinónimos informales (roto, plata)
P2	¿Cuánto tarda en llegar un pedido a Mendoza y cuánto sale el envío?	2.1	Dato de tabla: zona + plazo + costo
P3	¿Puedo pagar en 12 cuotas sin interés?	3.1	Trampa: 12 cuotas tienen recargo del 27%
P4	Compré auriculares in-ear, los abrí y me arrepentí. ¿Los puedo devolver?	4.1 + 4.4	Combinar regla general y excepción
P5	¿Tienen local a la calle para retirar el pedido en persona?	no figura	Debe aplicar la regla "No sé"

Matriz de datos A/B (10 corridas)

Estado del experimento: el banco de pruebas está construido y listo en n8n (workflow adjunto). La ejecución de las 10 corridas quedó **pendiente** por un problema de conexión con la instancia. Por eso esta matriz muestra la **estimación de costo previa a la ejecución**, calculada sobre los prompts y el contexto reales que recibe cada corrida. Las columnas de precisión las completa el nodo *Dashboard A/B* al ejecutar. **No son resultados medidos.**

Corrida	Modelo	Secciones recuperadas	Tokens agente	Tokens Juez	Costo agente USD	Costo Juez USD	Costo total USD	Exactitud	Veredicto
A-P1	gpt-4o-mini	4.2, 5	612	1061	0.00014	0.00333	0.00347	pendiente	pendiente
A-P2	gpt-4o-mini	2.1, 2.2	607	1056	0.00014	0.00331	0.00346	pendiente	pendiente

A-P3	gpt-4o-mini	3.1, 2.2	577	1025	0.00014	0.00324	0.00337	pendiente	pendiente
A-P4	gpt-4o-mini	4.4, 4.1	677	1126	0.00015	0.00349	0.00364	pendiente	pendiente
A-P5	gpt-4o-mini	7	513	961	0.00013	0.00308	0.00320	pendiente	pendiente
B-P1	gpt-4o	4.2, 5	612	1061	0.00235	0.00333	0.00568	pendiente	pendiente
B-P2	gpt-4o	2.1, 2.2	607	1056	0.00234	0.00331	0.00566	pendiente	pendiente
B-P3	gpt-4o	3.1, 2.2	577	1025	0.00227	0.00324	0.00550	pendiente	pendiente
B-P4	gpt-4o	4.4, 4.1	677	1126	0.00252	0.00349	0.00601	pendiente	pendiente
B-P5	gpt-4o	7	513	961	0.00211	0.00308	0.00519	pendiente	pendiente

Supuestos de la estimación: tokens de entrada = caracteres reales del prompt ÷ 3.8; salida del agente = 110 tokens; salida del Juez = 90 tokens; sin reintentos. Las secciones recuperadas son las que devuelve la búsqueda real del workflow para cada pregunta.

5. Dashboard y proyección a 1.000 ejecuciones

Proyección estimada (costo previo a la ejecución, ver supuestos en la sección 4). La precisión media y la frecuencia real de errores las calcula el nodo *Dashboard A/B* al ejecutar el lote.

1.000 ejecuciones A
USD 3,43
agente + Juez

1.000 ejecuciones B
USD 5,61
agente + Juez

Diferencia B – A
USD 2,18
cada 1.000

Peso del Juez en A
96%
del costo por corrida

Métrica	A · gpt-4o-mini	B · gpt-4o
Costo medio por corrida (USD)	0.00343	0.00561
· del agente	0.00014	0.00232
· del Juez (gpt-4o)	0.00329	0.00329
Proyección 1.000 ejecuciones (USD)	3,43	5,61
Proyección 1.000 sin Juez (USD)	0,14	2,32
Proyección 1.000 si el 20% necesita 1 reintento (USD)	4,11	6,73
Precisión media / aceptadas / escaladas	pendiente de ejecución	pendiente de ejecución

Categorías de error

Taxonomía que usa el Juez: `dato_inventado`, `dato_incompleto`, `sin_cita_de_fuente`, `fuera_de_politica`, `no_aplico_regla_no_se`, `tono_o_formato`. La batería está diseñada para provocar las más riesgosas. Estas son **hipótesis a validar**, no frecuencias medidas:

Pregunta	Error que pone a prueba	Por qué
P3 · 12 cuotas sin interés	<code>dato_inventado</code>	Riesgo: que el modelo confirme "sí, en 12 cuotas", cuando la política dice 6 sin interés y 12 con 27% de recargo.
P4 · auriculares abiertos	<code>dato_incompleto</code>	Aplicar solo el arrepentimiento (4.1) y omitir la excepción de in-ear abiertos (4.4).
P5 · local para retirar	<code>no_aplico_regla_no_se</code>	El contexto recuperado no responde (sección 7, datos personales); el agente debe decir "No sé" y no inventar una dirección.
P1, P2	<code>sin_cita_de_fuente</code>	Preguntas simples: el riesgo principal es que el agente responda bien pero omita la cita de la sección.

Recomendación comercial

Arrancar en producción con la Arquitectura A (gpt-4o-mini + Juez). Cada 1.000 ejecuciones cuesta USD 3,43 contra USD 5,61 de B, un 39% menos. El Juez y el Self-Healing compensan la menor capacidad del modelo económico. B solo se justifica si al ejecutar el lote evita más

escalamientos humanos de los que cuesta: con una revisión humana de USD 1, B tiene que evitar al menos 3 escalamientos cada 1.000 ejecuciones para pagarse.

Hallazgo de costo: el Juez explica el 96% del costo de A. La siguiente optimización no pasa por el agente sino por el supervisor. Hay dos caminos: un Juez más económico (gpt-4o-mini) para los casos simples, o evaluar con el Juez solo una muestra de las respuestas cuando la exactitud histórica sea alta.

Proyección = costo medio real por corrida $\times$ 1.000. Incluye agente, Juez y reintentos. No incluye el costo de la revisión humana de los casos escalados.