


Checkpoint Módulo 8 · Supervisor QA con AI-as-a-Judge

Lleyton Murphy · Agente de Soporte e-commerce (Lleyton Tech Store) · proyecto integrador M1 → M5 → M8

n8n Juez gpt-4o con JSON Schema Switch de 3 rutas Test A/B: 10 corridas

El agente de soporte de los módulos anteriores (RAG sobre el Manual de Políticas v2.1) ya no responde directo al cliente. Ahora cada respuesta pasa por un **Juez LLM** que la califica con salida JSON forzada. Un **Switch** decide si se envía, si se corrige con la crítica del Juez o si se escala a un humano. Cada veredicto queda registrado en una tabla de auditoría.


1. Arquitectura del supervisor



Nodo	Función
Recuperar contexto (Base de Conocimiento)	Lee las secciones del manual desde la Data Table <i>Base Conocimiento M8</i> (equivalente a <i>Airtable</i>) y elige las 2 más relevantes.
Agente Soporte (Arquitectura A / B)	Nodo OpenAI con el System Prompt RAG del M5 (cita la fuente y aplica la regla "No sé"). El modelo cambia según la arquitectura.
Payload JSON para el Juez	Arma el objeto {query_usuario, contexto_recuperado, respuesta_propuesta}.
Juez (AI-as-a-Judge · JSON Schema)	Nodo OpenAI gpt-4o con <i>Output Format = JSON Schema</i> : devuelve exactitud_factual, estado_veredicto, categoria_error y critica.
Procesar veredicto + costo	Valida el JSON. Si el Juez no devolviera un JSON válido, lo trata como RECHAZADO para que el Switch nunca reciba texto libre. Calcula tokens y costo.

Switch · Ruta según estado_veredicto	3 salidas: ACEPTAR / CORREGIR (Self-Healing) / ESCALAR (Human-in-the-loop).
Registrar veredicto (Data Table · auditoría)	Guarda cada veredicto en <i>Auditoria Juez M8</i> : repositorio externo para auditoría y fuente del dashboard.

Captura del sub-workflow en n8n



Workflow en n8n después de ejecutar el lote A/B del 08/10/2026: nodos en verde, loop de 10 corridas, Switch con las 3 rutas y los nodos de Gmail, Slack y Wait desactivados para el test.

2. Branching y umbrales

Ruta	Condición en el Switch	Acción	Límite / salida
ACEPTAR	estado_veredicto = "ACEPTADO" y exactitud_factual $\geq$ 4	Gmail envía la respuesta al cliente (salida real) y se registra el veredicto.	Fin del caso.
CORREGIR (Self-Healing)	estado_veredicto $\neq$ "RECHAZADO" y intento < 2	La crítica del Juez vuelve al agente, que reescribe la respuesta. El Juez la evalúa de nuevo.	Máximo 1 reintento. Si sigue sin aprobarse, va a ESCALAR.
ESCALAR (Human-in-the-loop)	estado_veredicto = "RECHAZADO", o salida por defecto (fallback) cuando ya no quedan reintentos	Alerta en Slack #ops-soporte con botones Aprobar / Editar y nodo Wait en modo <i>On Webhook Call</i> : la ejecución queda pausada hasta que un humano toca un botón.	Espera máx. 24 h. La decisión humana queda en la auditoría.

Por qué estos umbrales

- **Exactitud $\geq$ 4 para enviar:** 4 admite una omisión menor (por ejemplo, la cita de la sección) pero ningún dato incorrecto. Por debajo de 4 hay un error de contenido que no puede llegar al cliente.
- **Un solo reintento:** un segundo intento con la crítica corrige la mayoría de las omisiones. Más vueltas duplican el costo del Juez (el componente más caro) y alargan la respuesta sin garantía de mejora. Si falla dos veces, decide un humano.
- **RECHAZADO va directo a humano:** un dato inventado, una promesa fuera de política o un pedido de datos sensibles es un riesgo para la empresa, así que no se auto-corrige.

Qué se evitó (consigna)

Riesgo	Cómo se resolvió
Juez con respuesta en texto libre que rompe el Switch	Output Format = JSON Schema con enum en estado_veredicto, más una validación en código: si el JSON no es válido, se fuerza RECHAZADO y se escala.
Loop de auto-corrección sin límite ni salida humana	Regla intento < 2 en el Switch y fallback hacia ESCALAR (Slack + Wait).
Veredicto sin registrar	Toda corrida, por cualquier ruta, termina en <i>Registrar veredicto</i> (Data Table Auditoria Juez M8, 24 columnas).

3. Rúbrica del Juez

Prompt del Juez (System Message)

Sos el JUEZ DE CALIDAD (AI-as-a-Judge) del Agente de Soporte de Lleyton Tech Store. Recibis un objeto JSON con: query_usuario, contexto_recuperado y respuesta_propuesta. Evalua la respuesta SOL0 contra contexto_recuperado. No uses conocimiento propio.

RUBRICA exactitud_factual (entero 1-5):

5 = todos los datos (plazos, montos, porcentajes, condiciones) coinciden con el contexto, responde completo y cita la seccion.

4 = correcta y fiel al contexto, con una omision menor (por ejemplo falta la cita o un detalle secundario).

3 = parcialmente correcta: omite una condicion relevante o mezcla politicas distintas.

2 = mayormente incorrecta o incompleta, aunque no inventa datos.

1 = inventa datos que no estan en el contexto, contradice la politica o promete algo fuera de politica.

Caso especial: si el contexto NO contiene la respuesta y el agente responde "No sé" y ofrece derivar, es CORRECTO (5). Si en ese caso inventa una respuesta, es 1.

REGLAS DE VEREDICTO (estado_veredicto):

- ACEPTADO: exactitud_factual 4 o 5.

- CORREGIR: exactitud_factual 2 o 3 y el error se puede arreglar con tu critica.

- RECHAZADO: exactitud_factual 1, o la respuesta promete reintegros/excepciones fuera de politica, pide datos sensibles o es riesgosa para la empresa. Requiere revision humana.

categoria_error: la causa principal del problema ("ninguno" solo si la respuesta es perfecta).

critica: 1 a 3 frases concretas y accionables que digan que corregir y cual es la seccion correcta. Si es ACEPTADO con 5, escribi "Sin observaciones".

Responde UNICAMENTE con el JSON del esquema.

Esquema JSON forzado (Structured Outputs)

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
      "description": "Exactitud factual de la respuesta respecto del contexto (1 a 5)"
    },
    "estado_veredicto": {
      "type": "string",
      "enum": [
        "ACEPTADO",
        "CORREGIR",
        "RECHAZADO"
      ]
    },
    "categoria_error": {
      "type": "string",
      "enum": [
        "ninguno",
        "dato_inventado",
        "dato_incompleto",

```

```

        "sin_cita_de_fuente",
        "fuera_de_politica",
        "no_aplico_regla_no_se",
        "tono_o_formato"
    ]
},
"critica": {
    "type": "string",
    "description": "Critica accionable para el reintento"
}
},
"required": [
    "exactitud_factual",
    "estado_veredicto",
    "categoria_error",
    "critica"
],
"additionalProperties": false
}

```

Los dos campos que exige la consigna son `exactitud_factual` (entero 1–5) y `estado_veredicto` (ACEPTADO | CORREGIR | RECHAZADO). Se agregan `critica`, que es lo que el agente recibe en la ruta CORREGIR, y `categoria_error`, que alimenta el dashboard.

Entrada que recibe el Juez

```

{
  "query_usuario": "Puedo pagar en 12 cuotas sin interes?",
  "contexto_recuperado": "[Seccion 3.1 - Medios de pago y cuotas] Tarjeta de credito bancaria: hasta 6 cuotas sin interes ... 9 y 12 cuotas con recargo del 18% y 27% ...",
  "respuesta_propuesta": "<respuesta del agente>"
}

```

4. Experimento A/B

	Arquitectura A	Arquitectura B
Modelo del agente	gpt-4o-mini (económico)	gpt-4o (premium)
Precio por 1M tokens (entrada / salida)	USD 0,15 / 0,60	USD 2,50 / 10,00
Constante en ambas	Mismo System Prompt RAG, misma Base de Conocimiento, mismas 5 preguntas, mismo Juez (gpt-4o, temperatura 0, USD 2,50 / 10,00) y misma regla de 1 reintento.	

Hipótesis: B es más precisa en el primer intento y A necesita el Self-Healing para alcanzarla.

Métricas por corrida: exactitud y veredicto del Juez, ruta final, tokens reales, costo (agente + Juez) y latencia. Además, cada respuesta se revisó a mano contra el manual para medir si el Juez acierta.

Batería de preguntas (iguales para A y B)

#	Pregunta	Sección	Qué prueba
P1	Si me llega roto el celular, ¿me devuelven la plata?	4.2	Sinónimos informales (roto, plata)
P2	¿Cuánto tarda en llegar un pedido a Mendoza y cuánto sale el envío?	2.1	Dato de tabla: zona + plazo + costo
P3	¿Puedo pagar en 12 cuotas sin interés?	3.1	Trampa: 12 cuotas tienen recargo del 27%
P4	Compré auriculares in-ear, los abrí y me arrepentí. ¿Los puedo devolver?	4.1 + 4.4	Combinar regla general y excepción
P5	¿Tienen local a la calle para retirar el pedido en persona?	no figura	Debe aplicar la regla "No sé"

Matriz de datos A/B (10 corridas)

Corrida	Modelo	Exactitud (Juez)	Veredicto	Ruta final	Tokens	Costo agente USD	Costo Juez USD	Costo total USD	Latencias	Revisión humana
A-P1	gpt-4o-mini	5/5	ACEPTADO	ACEPTAR (1er intento)	1356	0.00013	0.00226	0.00238	3.8	✓ correcta
A-P2	gpt-4o-mini	5/5	ACEPTADO	ACEPTAR (1er intento)	1411	0.00013	0.00232	0.00245	3.1	✓ correcta
A-P3	gpt-4o-mini	5/5	ACEPTADO	ACEPTAR (1er intento)	1277	0.00011	0.00215	0.00227	3.1	✓ correcta
A-P4	gpt-4o-mini	5/5	ACEPTADO	ACEPTAR (1er intento)	1467	0.00014	0.00239	0.00253	3.0	✓ correcta

A-P5	gpt-4o-mini	5/5	ACEPTADO	ACEPTAR (1er intento)	1015	0.00008	0.00183	0.00190	2.7	✓ correcta
B-P1	gpt-4o	5/5	ACEPTADO	ACEPTAR (1er intento)	1316	0.00193	0.00220	0.00413	3.1	✓ correcta
B-P2	gpt-4o	5/5	ACEPTADO	ACEPTAR (1er intento)	1343	0.00183	0.00224	0.00407	2.6	✓ correcta
B-P3	gpt-4o	5/5	ACEPTADO	ACEPTAR (1er intento)	1229	0.00166	0.00210	0.00376	2.9	✓ correcta
B-P4	gpt-4o	5/5	ACEPTADO	ACEPTAR (1er intento)	1331	0.00167	0.00222	0.00389	2.8	✗ incorrecta
B-P5	gpt-4o	5/5	ACEPTADO	ACEPTAR (1er intento)	1015	0.00126	0.00183	0.00309	2.7	✓ correcta

Lote AB-20261008-142313 (08/10/2026), 10 corridas reales en n8n con los modelos de OpenAI. Tokens tomados del campo usage de cada respuesta; costo = tokens × precio de lista. Registro completo en la Data Table *Auditoria Juez M8*. Las respuestas textuales están en el Anexo.

Corrida previa de validación (lote AB-20261008-141824)

En la primera ejecución el nodo de OpenAI devolvió el veredicto del Juez en un formato que el parser no esperaba. El guardrail funcionó como estaba diseñado: las **10 corridas fueron a ESCALAR** (Slack + Wait) y ninguna respuesta salió al cliente sin validar. Se corrigió el parser para que acepte los formatos del nodo y se volvió a correr el lote completo. Es la evidencia real de la ruta de escalamiento y de que el Switch nunca recibe texto libre.

5. Dashboard y proyección a 1.000 ejecuciones

Precisión real A 5/5 · 100% Juez: 100%	Precisión real B 4/5 · 80% Juez: 100%	1.000 ejecuciones A USD 2,31 agente + Juez	1.000 ejecuciones B USD 3,79 agente + Juez
---	--	---	---

Métrica (lote real)	A · gpt-4o-mini	B · gpt-4o
Exactitud media según el Juez	5/5	5/5
Aceptadas por el Juez (1er intento)	5/5	5/5
Correctas según revisión humana	5/5 (100%)	4/5 (80%)
Reintentos de Self-Healing / escaladas	0 / 0	0 / 0
Tokens medios por corrida	1305	1247
Latencia media	3,15 s	2,82 s
Costo medio por corrida	USD 0.0023	USD 0.0038
· peso del Juez en el costo	95%	56%
Proyección 1.000 ejecuciones	USD 2,31	USD 3,79
Proyección 1.000 sin Juez	USD 0,12	USD 1,67

Categorías de error más frecuentes

Categoría	Casos	Dónde	Acción correctiva
Formato de salida del Juez no legible (integración)	10 de 10	Corrida previa de validación	Parser tolerante + guardrail que escala. Resuelto: 0 casos en el lote final.
"No sé" indebido (el agente se niega a responder aunque el contexto tiene la respuesta)	1 de 10	B-P4 (gpt-4o)	Reforzar el prompt del agente: usar "No sé" solo si ningún fragmento responde.
Falso aceptado del Juez (Juez permisivo)	1 de 10	B-P4: el Juez le dio 5	Agregar a la rúbrica: si el contexto contiene la respuesta y el agente dice "No sé", exactitud máx. 2 → CORREGIR.
Omisión menor	1 de 10	B-P3: no menciona las 6 cuotas sin interés	No bloquea: respuesta correcta (nivel 4–5).

Resultado vs. hipótesis: la hipótesis no se confirmó. B no fue más precisa que A, y A no necesitó Self-Healing en ninguna corrida.

Acuerdo Juez–revisión humana: **9 de 10 (90%)**. El Juez aceptó las 10 respuestas, así que en este lote no se activaron las rutas CORREGIR ni ESCALAR. ESCALAR sí quedó probada en la corrida previa (10/10).

Recomendación comercial

Pasar a producción con la Arquitectura A (gpt-4o-mini + Juez). En las 10 corridas reales igualó a B según el Juez (5/5, exactitud 5,0) y la superó en la revisión humana (5/5 contra 4/5). Además cuesta USD 2,31 cada 1.000 ejecuciones contra USD 3,79 de B, un 39% menos. B fue algo más rápida (2,82 s contra 3,15 s), pero esa diferencia no justifica el mayor costo ni su error en la pregunta de los auriculares.

Próximos pasos:

1. **Calibrar el Juez:** agregar la regla del "No sé" indebido, que fue su único error.
2. **Bajar el costo del supervisor:** en A el Juez es el 95% del costo. Probar un Juez gpt-4o-mini, o evaluar con el Juez una muestra de las respuestas cuando la exactitud histórica sea alta. Sin Juez, A costaría USD 0,12 cada 1.000.
3. **Ampliar la batería:** 5 preguntas por arquitectura es una muestra chica. Antes del despliegue masivo conviene repetir el A/B con 20–30 preguntas reales de clientes.

Proyección = costo medio real por corrida $\times$ 1.000. Incluye agente y Juez. No incluye el costo de la revisión humana de los casos escalados.

Anexo · Respuestas del agente (lote real)

Corrida	Respuesta del agente	Revisión humana contra el manual
A-P1	Si el celular llega roto y tiene una falla de fábrica dentro de los 30 días corridos desde la entrega, puedes optar por el cambio por una unidad nueva o el reembolso total. La tienda se hace cargo del envío de ida y vuelta en este caso. Pasados los 30 días, se aplica la garantía correspondiente. Fuente: Manual de Políticas v2.1, sección 4.2.	Correcta: falla de fábrica, 30 días, cambio o reembolso, envío a cargo de la tienda (4.2).
A-P2	El envío a Mendoza, que se encuentra en la zona de Interior, tarda de 3 a 5 días hábiles desde la acreditación del pago y tiene un costo de \$8.900. Si la compra supera los \$120.000, se bonifica el 50% del costo de envío. Fuente: Manual de Políticas v2.1, sección 2.1.	Correcta: Interior 3 a 5 días hábiles, \$8.900; suma bien la bonificación del 50% desde \$120.000 (2.2).
A-P3	No, no es posible pagar en 12 cuotas sin interés. Se pueden realizar pagos en 12 cuotas con un recargo del 27%. Para pagos en 6 cuotas sin interés, la compra mínima debe ser de \$30.000. Fuente: Manual de Políticas v2.1, sección 3.1.	Correcta: evita la trampa; 12 cuotas con 27% de recargo y hasta 6 sin interés (3.1).
A-P4	Lamentablemente, no podrás devolver los auriculares in-ear, ya que al abrir el precinto no se admite el arrepentimiento ni el cambio por modelo, salvo en caso de falla de fábrica. Según la política, los productos deben estar sin uso y con el embalaje original para poder ser devueltos. Si necesitas más información, puedes contactar a nuestro soporte. Fuente: Manual de Políticas v2.1, sección 4.4.	Correcta: aplica la excepción de in-ear con precinto abierto (4.4).
A-P5	No sé: esa información no figura en la documentación disponible. Puedo derivarte a un asesor humano si lo deseas.	Correcta: aplica la regla "No sé" y ofrece derivar.
B-P1	Si el celular llega roto y es considerado una falla de fábrica, puedes optar por un reembolso total o un cambio por una unidad nueva dentro de los 30 días desde la entrega. La tienda cubrirá los costos de envío. Fuente: Manual de Políticas v2.1, sección 4.2.	Correcta (4.2).
B-P2	El envío a Mendoza tarda entre 3 a 5 días hábiles desde la acreditación del pago y cuesta \$8.900. Fuente: Manual de Políticas v2.1, sección 2.1.	Correcta (2.1), más escueta.
B-P3	No, no es posible pagar en 12 cuotas sin interés. Las 12 cuotas tienen un recargo del 27%. Fuente: Manual de Políticas v2.1, sección 3.1.	Correcta: 12 cuotas con 27%; omite que hay 6 sin interés (omisión menor).
B-P4	No sé: esa información no figura en la documentación disponible. Puedo derivar tu consulta a un asesor humano para más detalles.	Incorrecta: responde "No sé" aunque el contexto traía la sección 4.4, que sí responde. El Juez la aceptó con 5 (falso aceptado).

B-P5	No sé: esa información no figura en la documentación disponible. Te puedo derivar a un asesor humano para más detalles.	Correcta: aplica la regla "No sé".
------	---	------------------------------------